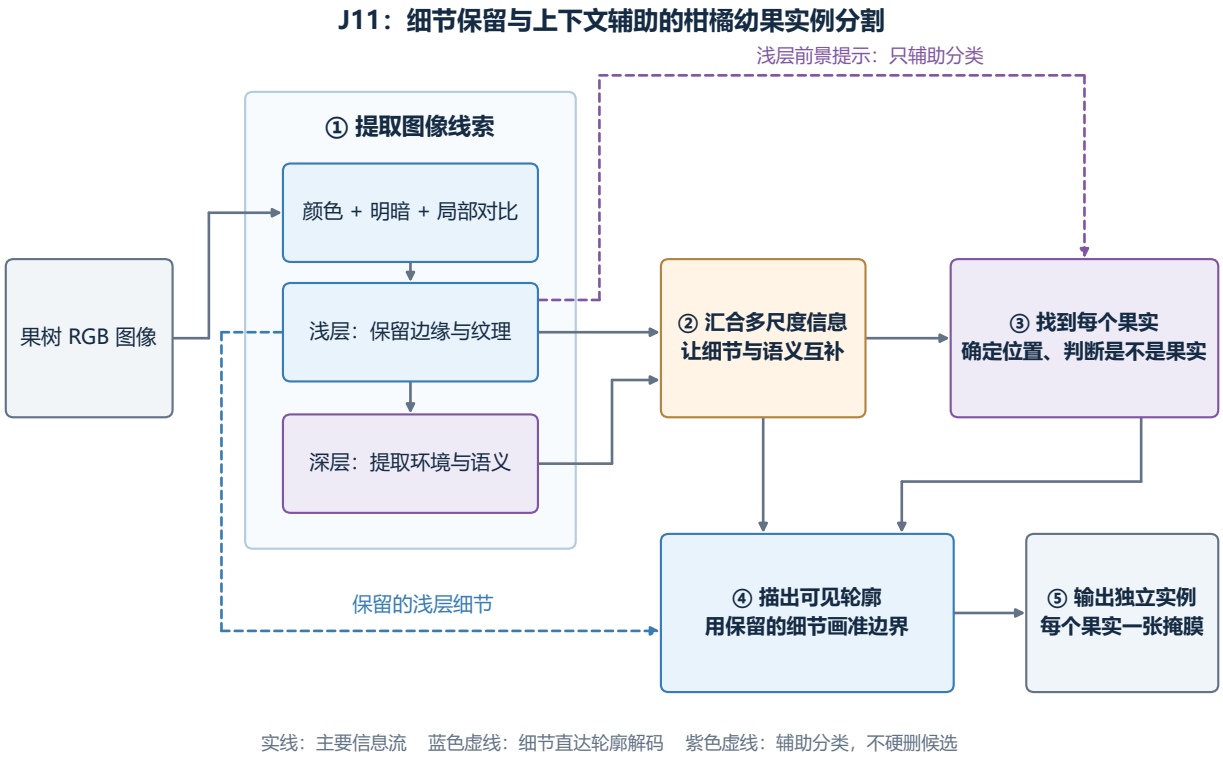
CITRUS INSTANCE SEGMENTATION

J11 柑橘幼果实例分割

数学推导、模块图解与证据边界

回答三个问题：为什么这样设计？
哪些性质能够证明？还需要哪些实验？



阅读前提　J11 是当前结构完整、预算较低的**综合候选**，不是已证实的精度冠军。本文件不把代数性质等同于 mAP 提升，也不把旧验证集成绩当正式测试集结论。图中“找到”“保留”等措辞表示设计目的，不表示目标已经达成。

面向 RGB 未成熟柑橘**可见实例掩膜**，不补全遮挡部分

源码核对日期：2026 年 10 月 1 日　排版：XeLaTeX

先给结论：强在哪里，为什么暂时不能说“最强”

J11 最值得研究的并不是又增加了一种注意力，而是把有限计算分给不同任务：**低通道浅层保留空间细节；检测分支在 P3/P4/P5 建立实例；P1/P2 直接支撑轮廓解码；深层上下文仅作有界残差修正**。这是一种可检验的任务分流结构。

本文件能够支持的判断，与不能越过的证据边界

设计机制	可严格推导的性质	不能由此推出的结论
相位重排入口	重排算子是可逆置换	重排后压缩、整个主干都无损
局部对比线索	对公共亮度偏移不变	灰度增加信息，或解决所有绿色混淆
竞争式融合	混合前的凸包界及显式权重梯度	全网络非扩张，或弱小目标必被增强
差分上下文	公共常量分量消除，读取代价与槽数有关	所有树叶被消除，或果实一定保留
浅层原型解码	更细原型栅格；线性 logits 秩上界	自动获得新候选，或高分辨率必涨点
有界修正	相对残差系数有界、初始恒等	训练全局收敛，或优化器具有 PID 稳定性

本地统一输入 640×640、单类构建诊断得到 J11 参数约 1.075 M、估算计算量 5.216 GFLOPs；匹配内部对照 J00 为 2.843 M、10.356 GFLOPs。但同一次 **CPU** 微基准的前向中位耗时是 123.1 ms 对 118.8 ms，因此**低参数、低 FLOPs 已有证据，“更快”和“精度最高”没有证据**。这是当前最重要的结论边界。

如何阅读

每项核心设计按“实际公式—命题—证明—任务意义—反例”展开。蓝色框给出直观解释；橙色提示给出不能过度解读的条件。解析示意图不是训练曲线；历史诊断图与 J11 的成绩严格分开。文末列出可直接用于实验验证的比较关系和参考文献。

目录

结论与阅读说明 1

1 任务定义与证据：先解释为什么极小目标困难 3

2 J11 的真实计算图与符号 4

3 入口推导：灰度与局部对比，增加的是归纳偏置 5

4 下采样推导：可逆重排与不可逆压缩要分开 6

5 轻量主干推导：空间混合便宜，不代表整网更快 7

6 颈部推导：一次式竞争融合的优点与风险 8

7 融合为何不等于抗混叠或全网稳定 9

8 上下文推导：有限槽位差分读取的可证明部分 10

9 差分机制的反例、复杂度和初始化 11

10 掩膜推导：把空间细节与实例发现分开 12

11 召回上限：细原型不能单独解决候选漏检 13

12 识别先验推导：软门控不是硬筛选，也不是完全解耦 14

13 损失推导：已经实现的项与尚未使用的项 15

14 控制式梯度预算：有条件的一步下降推导 16

15 PR 末端推导：横轴不是置信度，零补齐不是新的观测 17

16 哪些优势已有证据，哪些必须通过消融证实 18

参考文献 19

复核与来源账本 20

1 任务定义与证据：先解释为什么极小目标困难

设 RGB 图像为 $X \in \mathbb{R}^{3\times H\times W}$，标注为可见实例集合 $\mathcal{G}=\{(b_i, M_i)\}_{i=1}^{n}$，其中 $M_i \in \{0,1\}^{H\times W}$ 不包含被叶枝遮挡、无法看见的区域。模型预测 $\{(\hat{b}_j, s_j, \hat{M}_j)\}$，需要同时完成候选发现、分数排序和掩膜拟合。**“绿色相近”是混淆假设，不是仅凭颜色相近就已证明的错误归因。**

1.1 像素误差的尺度放大效应

命题 1.1 (同尺寸方形掩膜的平移敏感性)**.** *两个边长为 $d>0$ 的方形掩膜沿横、纵方向同时相差 δ，且 $0\le\delta\le d$，则*

$$\mathrm{IoU}(d,\delta)=\frac{(d-\delta)^2}{2d^2-(d-\delta)^2}. \tag{1}$$

若要求 $\mathrm{IoU}\ge\tau$，其中 $0<\tau<1$，则充要条件为

$$\frac{\delta}{d}\le 1-\sqrt{\frac{2\tau}{1+\tau}}. \tag{2}$$

证明. 交集面积为 $(d-\delta)^2$，并集面积为两方形面积之和减交集，得到式(1)。记 $r=\delta/d$，则 $(1-r)^2/[2-(1-r)^2]\ge\tau$ 等价于 $(1-r)^2\ge 2\tau/(1+\tau)$。由于 $1-r\ge 0$，取非负平方根即得式(2)。 □

当 $\tau=0.5$ 时，允许相对偏移仅约 18.35%。$\delta=1$ 像素时，$d=4,8,16$ 对应 IoU 分别为 $9/23\approx0.391$、$49/79\approx0.620$、$225/287\approx0.784$。

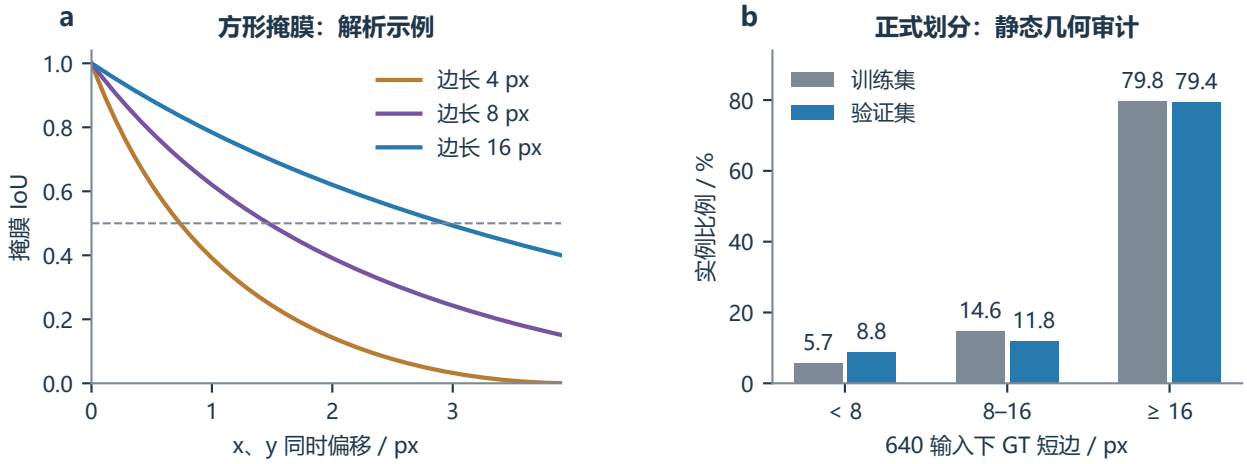


图 1 (a) 方形掩膜解析曲线，不是模型成绩；(b) 正式 grouped_dedup 划分在静态 letterbox640 下的 GT 短边比例。训练集 4,120 个、验证集 1,181 个实例；没有增强、没有预测，也不代表召回。

对本任务的含义 应减少输入缩小、边界栅格和实例合并造成的相对误差；但仅仅把输出原型做细，不能恢复输入里已经不可区分的目标，也不能替代候选发现。

适用边界：真实果实有深凹可见轮廓和遮挡，不是方形；上述精确公式是敏感性分析，不是实际 AP 定律。静态几何审计也不能替代增强后标签分配和难例诊断。

2 J11 的真实计算图与符号

下表直接对应 `J11_synthesis.yaml`。批量维度省略，C_k 表示主干特征，P_k 表示送给头部的融合特征；二者不要混用。

表 1 J11 在 640 输入、单类任务下的张量契约

符号	形状：通道 × 空间	对应操作与任务
C_1	16×320^2	RGB/亮度/局部对比，相位重排入口；保留早期细节
C_2	32×160^2	JDown + JStage×2；掩膜细节及场景监督
C_3	64×80^2	JDown + JStage×2；检测尺度 8
C_4	96×40^2	JDown + JStage×3 + JContext；上下文尺度 16
C_5	160×20^2	JDown + JStage×2 + SPPF；深层语义
P_3	64×80^2	$\mathcal{F}_3(C_3, C_2, C_4)$
P_4	96×40^2	$\mathcal{F}_4(C_4, C_3, C_5)$
P_5	128×20^2	$\mathcal{F}_5(C_5, C_4)$
$\mathcal{P}$	32×320^2	$C_2 + P_3$ 的语义细节与 C_1 合成原型

2.1 结构上的关键变化

$$(C_1, C_2, C_3, C_4, C_5) = \mathcal{E}(X), \qquad P_k = \mathcal{F}_k(\mathcal{S}_k), \quad k \in \{3, 4, 5\}. \tag{3}$$

JStage 不是原版 C3k2/CSP 堆叠；颈部从各主干尺度**分别读取并一次式融合**，没有重复完整的自顶向下、自底向上 PAN 路径。头部的框、分类和实例系数仍复用 Ultralytics 的检测接口；掩膜原型采用独立细节路径。**这是新的编码和融合设计，但不是摆脱所有 YOLO 实现依赖的完全独立框架。**

$$N_{\text{cand}} = 80^2 + 40^2 + 20^2 = 8400. \tag{4}$$

C_1/C_2 参与掩膜或场景支路，**没有**增加 stride 2/4 的检测候选。因此本文不能把细节分支描述成“全程高分辨率检测主线”或“已有 P2 小目标检测头”。

为什么选择它来讲推导 它同时具备细节入口、低通道非 CSP 主干、不同尺度的直接融合、有限槽位上下文和独立轮廓解码，适合分析计算如何服务本任务。综合性是选择理由，不是精度排名的证据。

3 入口推导：灰度与局部对比，增加的是归纳偏置

实际亮度通道为

$$Y(p) = 0.2989X_R(p) + 0.5870X_G(p) + 0.1140X_B(p), \qquad Q(p) = Y(p) - \frac{1}{|\mathcal{N}_p|}\sum_{q\in\mathcal{N}_p} Y(q). \tag{5}$$

$\mathcal{N}_p$ 是 5×5 邻域与有效图像区域的交集。实现使用 `count_include_pad=False`，边界处也按有效像素计均值。入口拼接为 $Z = [X, Y, Q] \in \mathbb{R}^{5\times H\times W}$。

命题 3.1 (局部对比的公共亮度偏移不变性)**.** *对任意常量 a，定义 $Y'(p) = Y(p) + a$。如果邻域平均的权重和为 1，则 $Q'(p) = Q(p)$，包括采用有效像素归一化的边界位置。*

证明. $Q'(p) = Y(p) + a - |\mathcal{N}_p|^{-1}\sum_q (Y(q) + a) = Y(p) - |\mathcal{N}_p|^{-1}\sum_q Y(q) = Q(p)$。 □

此性质针对**亮度域的公共加法偏移**，不是对曝光缩放、局部阴影、饱和裁剪或任意色变都不变。灰度转化也可能压低仅由色度体现的果叶差异，因此 RGB 始终保留。

命题 3.2 (确定性附加通道不会凭空增加信息)**.** *设目标随机变量为 T，$g(X) = (Y, Q)$ 为 RGB 的确定性函数。在相关互信息存在的条件下，*

$$I(T; X, g(X)) = I(T; X). \tag{6}$$

证明. 互信息链式法则给出 $I(T; X, g(X)) = I(T; X) + I(T; g(X) \mid X)$。给定 X 后 $g(X)$ 已确定，条件互信息为零。 □

为什么仍可能有用 不是给模型额外传感器，而是把“相对明暗变化”显式放到可读取的通道，减少低预算网络自行学出同类滤波的负担。这个优化和泛化假设必须由 J05 与 J06 的同协议实验、颜色扰动及果叶误报统计验证。

3.1 可发表的准确表述

可写“引入显式的无色度细节归纳偏置”，不能写“增加新的物理信息”或“数学证明灰度比 RGB 更强”。这里只提出针对任务的表示方式；与 RGB 的互补性尚待实测。

4 下采样推导：可逆重排与不可逆压缩要分开

当 H, W 为偶数，定义空间到通道的相位重排 $\mathcal{U}$：

$$[\mathcal{U}(Z)]_{4c+2a+b,i,j} = Z_{c,2i+a,2j+b}, \qquad a, b \in \{0, 1\}. \tag{7}$$

它将 $C \times H \times W$ 变为 $4C \times H/2 \times W/2$，元素总数不变。JStem 模式 2 先把 5 通道重排为 20 通道，再学习投影到 16 通道；JDown 同样先重排，再执行 1×1 Conv-BN-SiLU 投影。

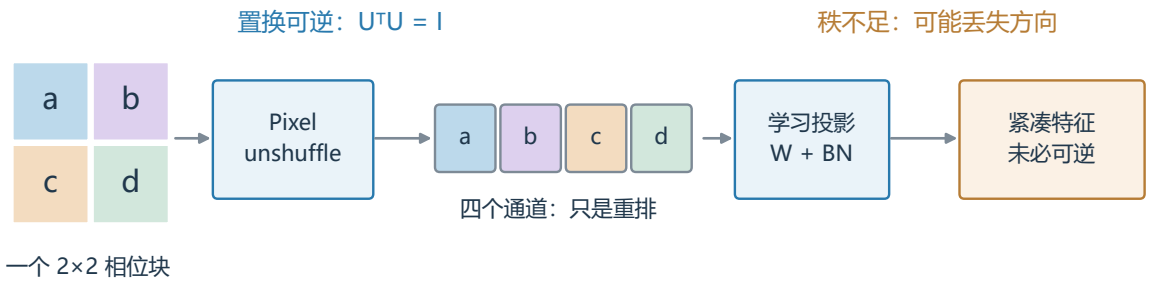


图 2 原创相位示意。a、b、c、d 代表相邻空间位置，不是四个独立语义。可逆的是重排本身，右侧学习压缩不继承可逆保证。

命题 4.1 (重排是等距置换)**.** *将张量向量化后，$\mathcal{U}$ 对应置换矩阵 U，满足*

$$U^{\mathsf{T}}U = I, \qquad U^{-1} = U^{\mathsf{T}}, \qquad \|Uz\|_2 = \|z\|_2. \tag{8}$$

证明. 式(7)为每个输入元素建立唯一输出索引，反向索引唯一。置换矩阵每行、每列恰有一个 1，其余为 0，所以正交；范数结论随即成立。 □

命题 4.2 (学习压缩的非单射条件)**.** *令 $W \in \mathbb{R}^{C_{\text{out}} \times 4C}$。若存在非零 $v \in \ker W$，并且 $z, z+v$ 均属于允许输入域，则 $Wz = W(z+v)$。任何仅作用于 Wz 的后续变换均无法区分两者。*

证明. 由线性性，$W(z+v) = Wz + Wv = Wz$。施加相同后续函数仍相等。 □

当 $C_{\text{out}} < 4C$ 时，秩-零化度定理保证在完整特征空间有非平凡核。例如 $W = [1\ 1]$，$v = [1\ -1]^{\mathsf{T}}$ 被完全抹去。

适用边界：入口的 Y/Q 是 RGB 的确定性冗余；20 到 16 通道**不能仅凭维数**就证明真实 RGB 流形上必有信息丢失。JDown 的完整特征域则仍具有上述压缩风险。准确主张是“压缩前保留四相位供学习选择”，不是“整个主干无损”。

5 轻量主干推导：空间混合便宜，不代表整网更快

对 $F \in \mathbb{R}^{C\times h\times w}$，设 $a = \lfloor C/4 \rfloor$，将通道分为 F_A, F_B。JStage 内单个实际残差块为

$$\begin{aligned} \widetilde{F} &= [\mathrm{Conv}_{3\times3}(F_A), F_B], \\ V &= \mathrm{Conv}_{1\times1}(\widetilde{F}), \qquad G = \mathrm{sigmoid}\Big(W_g\,\mathrm{DWConv}_{5\times5}(\widetilde{F}) + b_g\Big), \\ F^{+} &= F + \tanh(\boldsymbol{g}) \odot \mathrm{Conv}^{\text{no act}}_{1\times1}(V \odot G). \end{aligned} \tag{9}$$

其中 Conv 包含代码约定的 BN/激活，最后投影仅关闭激活、仍有 BN。$\boldsymbol{g}$ 为逐通道参数，初值 0.1；门 G 在 $(0,1)$，但残差值和投影权重不受范数约束。设计借鉴部分通道空间卷积思路 [1]，并非 FasterNet 整网复现。

5.1 算术复杂度

忽略 BN、激活和逐元素操作，标准 3×3 全通道卷积的 MAC 数为 $9hwC^2$。只在四分之一通道上卷积，则

$$\mathrm{MAC}_{\text{partial}} = 9hwa^2 \approx \frac{1}{16}\,9hwC^2. \tag{10}$$

这仅是空间卷积分量的节省，不是整个块节省 16 倍。式(9)还包含三个 $C \to C$ 点卷积和一个深度卷积，约为

$$\mathrm{MAC}_{\text{block}} \approx hw\left(9a^2 + 3C^2 + 25C\right). \tag{11}$$

本文 FLOPs 诊断采用乘加算 2 次浮点操作的惯例，并另补 JContext 矩阵乘部分。未计池化、插值、张量重排、所有非线性与数据搬运，所以为**估算值**，不是硬件性能证明。

表 2 本地 CPU 构建诊断；不是训练结果，也不是 GPU 推理测试

模型	参数 / M	估算 GFLOPs	CPU 前向中位时间 / ms
J00 匹配内部对照	2.843	10.356	118.8
J11 综合候选	1.075	5.216	123.1
J17 进一步压缩	0.709	3.875	128.1

实际含义 J11 参数约减少 62.2%，估算 FLOPs 约减少 49.6%，但此 CPU 诊断并未更快。碎片化小算子、内存读写和调度足以抵消算术量优势；最终必须在同 GPU、同 batch、同部署路径测量。对精度而言，轻量主干可能失去容量，需用更低预算换来的细节路径收益证明其值得。

6 颈部推导：一次式竞争融合的优点与风险

对一个目标尺度，来源特征先经点卷积投影，再按目标大小做平均池化或最近邻上采样：

$$V_i = \mathcal{R}_i(\phi_i(C_i)), \quad \boldsymbol{a}(p) = W_s[V_1(p), \dots, V_K(p)] + b_s, \quad \alpha_i(p) = \frac{e^{a_i(p)}}{\sum_j e^{a_j(p)}}. \tag{12}$$

ϕ_i **在重采样之前**执行，这与“先上采样，再投影”的成本、数值行为不同。实际输出为

$$F(p) = \sum_{i=1}^{K} \alpha_i(p) V_i(p), \qquad P = \psi_{\text{DW3+PW1}}(F). \tag{13}$$

空间自适应尺度权重已有 ASFF 先例 [2]；本文可研究的重点是**低预算直接拓扑和任务分流**，不能把 softmax 加权本身宣称为首次提出。

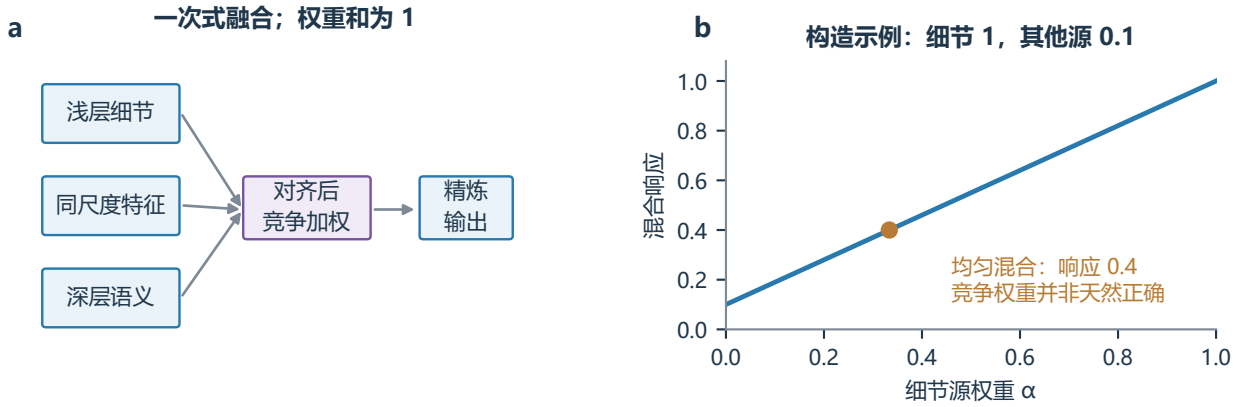


图 3 (a) 每个目标尺度从主干直接读取；(b) 人工数值示例：细节源响应为 1，其余两个源为 0.1，细节权重为 1/3 时混合响应为 0.4。曲线不是训练权重或真实果实激活。

命题 6.1 (精炼前的凸包界与竞争梯度)**.** *固定各源值 $V_i(p)$，则 $F(p)$ 属于其凸包，任意范数满足*

$$\|F(p)\| \le \sum_i \alpha_i(p)\|V_i(p)\| \le \max_i \|V_i(p)\|. \tag{14}$$

对任一权重 logit a_j 有

$$\frac{\partial F}{\partial a_j} = \alpha_j(V_j - F). \tag{15}$$

证明. softmax 产生非负且和为 1 的权重，因此为凸组合，范数不等式由三角不等式得到。由 $\partial\alpha_i/\partial a_j = \alpha_i(\mathbf{1}_{i=j} - \alpha_j)$，代入式(13)即得梯度。 □

若上游损失梯度为 $h = \partial\mathcal{L}/\partial F$，则 $\partial\mathcal{L}/\partial a_j = \alpha_j\langle h, V_j - F\rangle$，说明权重可学习是否需要某来源。

适用边界：这个方向由损失决定，不等于网络知道“哪个是果实”。零初始化的权重是均匀混合，可能稀释仅一个尺度可见的微弱目标。

7 融合为何不等于抗混叠或全网稳定

7.1 输入导数不是简单的凸平均

当来源和权重都依赖输入 x 时，完整导数为

$$\frac{\partial F}{\partial x} = \sum_i \alpha_i \frac{\partial V_i}{\partial x} + \sum_i V_i \frac{\partial \alpha_i}{\partial x}. \tag{16}$$

第二项不能省略；$P = \psi(F)$ 还引入学习投影的导数。因此凸包界(14)不是输入扰动非扩张证明，不是全网 Lipschitz 常数小于 1 的证明。

7.2 平均池化对稀疏信号的稀释

设一个池化窗有 m 个位置，其中只有 r 个位置含幅值 A 的额外目标响应，其余为同一背景 B。则平均池化为

$$\overline{V} = B + \frac{r}{m} A. \tag{17}$$

$r \ll m$ 时，该来源的目标残差幅值按占比减小；这是明确反例。最大池化有不同的信息偏置，最近邻上采样不创造新的真实边界；没有某个简单算子自动同时解决所有问题。频率感知融合研究 [6] 提供了可研究方向，但 J11 **没有**实现其频率估计、自适应滤波或位移校正，不能引用其整套性质给当前 JFusion 背书。

7.3 一次式直接融合的合理研究假设

$$C_i \longrightarrow P_k \longrightarrow \text{实例头}, \quad \text{而不是反复经过多轮融合才读出浅层信息。} \tag{18}$$

更短的信息路径可能减少重复变换造成的细节稀释；较少高分辨率中间节点可能降低计算预算。**“路径更短”是结构事实，“信号更好”仍是实验假设：**来源不一致、空间错位、投影瓶颈、均匀初值都可能使其失败。

最有价值的验证 不要只看总 mAP。比较 J05 的均匀融合与 J08 的竞争融合，统计超小目标召回、果叶误报、权重熵和失败样例；再比较同预算普通 PAN 与直接拓扑。若只替换模块却不控制主干、掩膜分辨率和训练协议，就不能归因到融合方式。

8 上下文推导：有限槽位差分读取的可证明部分

在 C_4 上，$N = 40^2 = 1600$，通道投影维度 $d = 16$，上下文池化到 4×4，故记忆槽数 $m = 16$。令 $Q_1, Q_2 \in \mathbb{R}^{N\times d}$，$K_1, K_2, V \in \mathbb{R}^{m\times d}$。实际读取为

$$A_1 = \mathrm{softmax}\left(Q_1 K_1^{\mathsf{T}}/\sqrt{d}\right), \qquad A_2 = \mathrm{softmax}\left(Q_2 K_2^{\mathsf{T}}/\sqrt{d}\right),$$
$$D = A_1 - A_2, \qquad R = DV, \qquad F^{+} = F + 0.25\tanh(g) W_o R. \tag{19}$$

softmax 沿记忆槽方向执行，g 初值为 0。借鉴差分注意力及压缩视觉对比思想 [4, 3]，但当前没有原论文的完整双阶段交互、位置编码、可学习差分系数或全部归一化机制。

命题 8.1 (公共常量分量消除与有限读出界)**.** *在精确实数运算下，$D\mathbf{1}_m = 0$。若 $V = \mathbf{1}_m v_0^{\mathsf{T}} + E$，则*

$$DV = DE, \qquad \|D\|_\infty \le 2, \qquad \|DV\|_{\max} \le 2\|V\|_{\max}, \tag{20}$$

其中 $\|\cdot\|_\infty$ 为最大绝对行和，$\|\cdot\|_{\max}$ 为元素绝对值的最大值。

证明. 每个概率矩阵的行和都是 1，所以 $(A_1 - A_2)\mathbf{1}_m = 0$。常量部分右乘后为零，得到 $DV = DE$。每行有 $\sum_j |A_{1,ij} - A_{2,ij}| \le \sum_j (A_{1,ij} + A_{2,ij}) = 2$，再逐元素应用三角不等式得到幅值界。 □

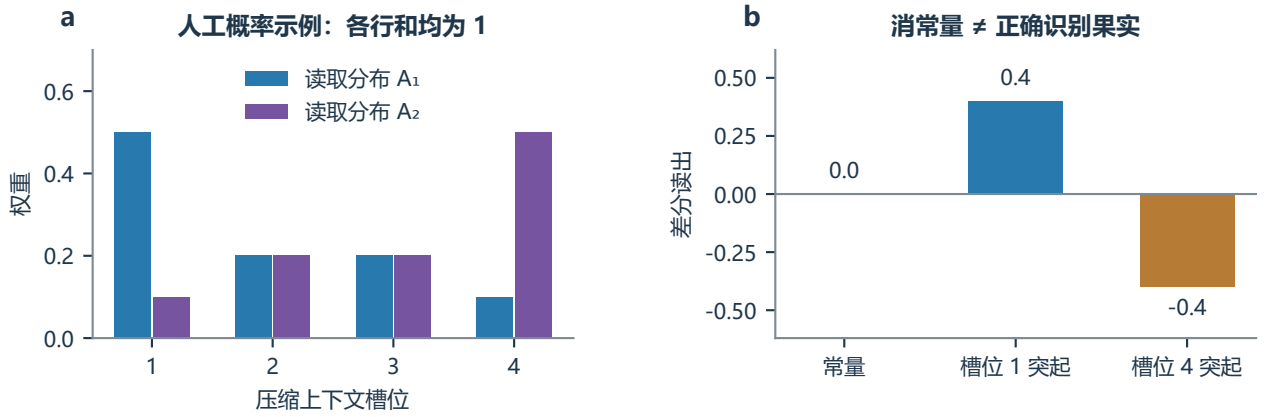


图 4 人工概率例子展示公共常量消除。槽位 1 与 4 的局部突起产生相反符号，不代表“正值是果实、负值是叶片”。图中槽位数为 4，便于阅读；代码使用 16。

为什么值得尝试 绿色果叶共享部分低区分度响应时，差分读取具备去公共分量的代数能力。但这个公共分量是否对应背景，需要特征可视化和错误统计证明；真实叶片是空间变化信号。

9 差分机制的反例、复杂度和初始化

9.1 不能用零行和证明“自动去叶片”

如果果实的有效信号也在所有槽位中相同，命题8.1同样会将其消去。若 $A_1 = A_2$，则所有 V 都得到 $DV = 0$。因此差分读取有**语义不确定性**，仅保证消除数学上的公共常量，不保证目标/背景分解正确。此外，4×4 的 C4 池化槽在 640 输入下覆盖约 160×160 像素，极小果实可能在池化时被式(17)稀释。该支路适合辅助上下文，不应承担唯一的小目标保留任务。

9.2 读取矩阵的计算代价

两个 QK^{T} 需要 $2Nmd$ 次 MAC，差分后的 DV 需要 Nmd 次 MAC，合计

$$\mathrm{MAC}_{\mathrm{read}} = 3Nmd, \qquad \mathrm{FLOPs}_{\mathrm{read}} \approx 6Nmd. \tag{21}$$

代入 $N = 1600, m = d = 16$ 为 2,457,600 FLOPs，即约 0.00246 GFLOPs。注意力矩阵存储量为 $O(Nm)$，当 m 固定时对 N 线性。

适用边界：这只计算读取矩阵；Q/K/V/out 的卷积、池化和 softmax 成本仍存在。相比**同维数同读取形式**的全 N 槽方案，矩阵项约缩为 m/N，不能据此说整网快 100 倍。

9.3 零初始化不是训练全过程冻结

把 $R_\theta(F) = W_o DV$ 记为上下文分支，则

$$F^+ = F + 0.25\tanh(g)R_\theta(F), \quad \left.\frac{\partial F^+}{\partial \theta}\right|_{g=0} = 0, \quad \left.\frac{\partial F^+}{\partial g}\right|_{g=0} = 0.25R_\theta(F). \tag{22}$$

初始前向为恒等；首步分支内部梯度为零，但门参数一般仍有梯度。本地已有构造反向检查观察到 gain 梯度 L1 约 0.137，而 q/k 梯度为 0，符合公式。这不是训练成功保证；若门始终不打开，该分支也可能长期无贡献。

$$\|F^+ - F\| \le 0.25\|R_\theta(F)\|. \tag{23}$$

系数有界不等于 R_θ 有界；学习权重未施加谱范数约束，因此没有全网络稳定性定理。

10 掩膜推导：把空间细节与实例发现分开

实际 J11 原型构造为

$$B_2 = \phi_2(C_2) + \mathrm{Up}_2\big(\phi_3(P_3)\big),$$
$$B_1 = [\mathrm{Up}_2(B_2), \phi_1(C_1)], \qquad \mathcal{P} = \psi_{\mathrm{DW3+PW1}}(B_1). \tag{24}$$

ϕ_2, ϕ_3 投影到 32 通道，ϕ_1 投影到 16 通道，拼接得到 48 通道，最终得到 32 张 320×320 原型。系数 $c_j \in \mathbb{R}^{32}$ 来自 P3/P4/P5；在原型网格上预测

$$L_j(p) = \sum_{k=1}^{32} c_{jk}\mathcal{P}_k(p), \qquad \hat{M}_j = \mathrm{Crop}_{\hat{b}_j}\big(\mathrm{sigmoid}(L_j)\big). \tag{25}$$

原型与系数分解已有 YOLACT 先例 [5]；本文重点是**细节直接进入原型的拓扑分配**，不是声称首创线性原型解码。

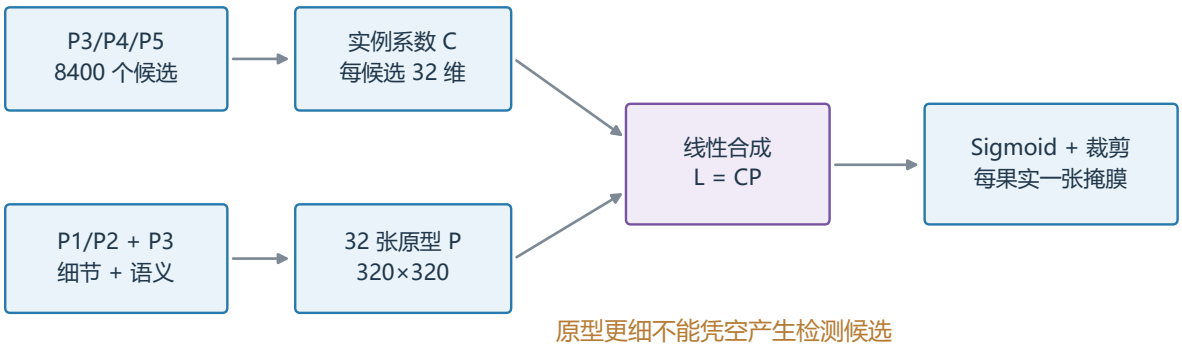


图 5 掩膜解码真实分流：C1/C2 支撑高分辨率原型，P3/P4/P5 建立实例系数。P1/P2 不是额外检测头；一个目标没有候选时，原型不会自动输出对应实例。

命题 10.1 (线性原型的表达秩上界)**.** *忽略裁剪和 sigmoid，将原型向量化为 $P \in \mathbb{R}^{32\times S}$，实例系数矩阵为 $C \in \mathbb{R}^{n\times 32}$，则所有实例 logits 为 $L = CP$，且*

$$\mathrm{rank}(L) \le \min\{\mathrm{rank}(C), \mathrm{rank}(P)\} \le 32. \tag{26}$$

证明. 矩阵乘积的像空间包含于左因子像空间，行空间包含于右因子行空间，所以得到秩上界。 □

适用边界：该界作用于线性 logits；各实例不同裁剪和非线性阈值后的二值掩膜不继承同一秩界。更多原型可能增加表达能力，也增加计算和拟合风险；不能说 32 张一定足够或一定不足。

11 召回上限：细原型不能单独解决候选漏检

11.1 先定义才谈“召回上限”

设低阈值候选集合为 $\mathcal{C}(X)$。按一对一匹配，将标注拆成 $\mathcal{G}_{\text{avail}}$ 与 $\mathcal{G}_{\text{miss}}$：前者存在可服务该实例的候选，后者不存在。在“掩膜必须由候选生成、解码不生成额外实例”的条件下，最终正确实例数满足

$$N_{\text{TP}} \le |\mathcal{G}_{\text{avail}}|, \qquad R \le R_{\text{avail}} := \frac{|\mathcal{G}_{\text{avail}}|}{|\mathcal{G}|}. \tag{27}$$

这是由输出机制得到的**条件性计数上界**，不是用某个任意 box IoU 指标直接替代 mask 上界。候选匹配标准必须与实例可服务的定义一致；不能把框 IoU 0.5 简单当成所有 mask IoU 0.5 的充要条件。

11.2 小目标的损失链条要逐段定位

输入可区分性 → 特征响应 → 实际正样本分配 → 候选和排序 → 掩膜拟合 → 跨视图合并. (28)

当前 TAL 对小目标**资格区域**做了至少 16 像素的短边扩展，回归目标仍为原框。静态无增强 train/val 几何审计中，扩展后零资格中心实例数均为 0；因此“P3 网格没有中心点就是现在所有漏检的原因”**不成立**。但资格中心存在，仍不保证 top-k、对齐分数及目标竞争后实际分配到正样本。

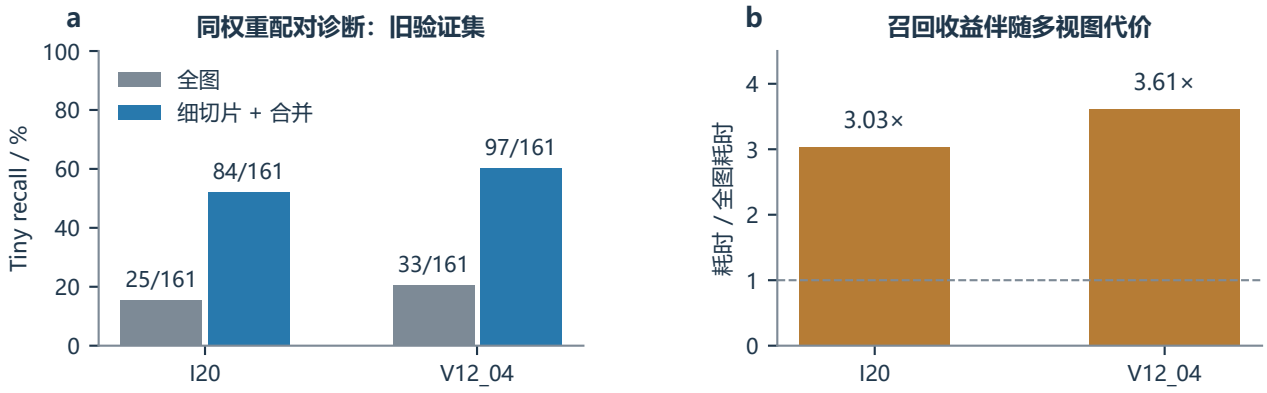


图 6 历史冻结权重配对诊断。Tiny 指 640 公共栅格上可见 GT mask 面积 < 256；分数阈值 0.25、mask IoU 0.5、一对一匹配，分母 161。每模型只有一个 checkpoint，未给跨 seed 误差棒。旧验证集不是正式 grouped_dedup 验证集；细切片包含合并规则变化，不能孤立归因于像素尺度，更不是 J11 的成绩。

已有证据的正确用途 切片与合并可明显改变同权重的小目标召回，但增加端到端耗时。这支持“应优先研究可见信息与候选链”的方向，不支持“增加一个模块即可复现所有提升”。SAHI 提供了切片推理先例 [7]，切片本身不构成全新理论创新。

12 识别先验推导：软门控不是硬筛选，也不是完全解耦

J11 的 C2 场景支路产生两个 logits：前景并集 S_f 与可见实例边界并集 S_b。只将前景概率 $\pi = \mathrm{sigmoid}(S_f)$ 对各检测尺度池化，并用于分类特征：

$$\widetilde{P}_k = P_k \odot \left[1 + 0.25 \tanh(g_s)\, \mathrm{Pool}_k(\pi)\right]. \tag{29}$$

框与系数 tower 直接读取原来的 P_k，分类 tower 读取 $\widetilde{P}_k$；g_s 初值 0。

命题 12.1 (前景门的相对调制范围)**.** *在每个特征位置，$\mathrm{Pool}_k(\pi) \in [0,1]$，因此调制系数*

$$0.75 \le 1 + 0.25 \tanh(g_s)\, \mathrm{Pool}_k(\pi) \le 1.25. \tag{30}$$

且 $g_s = 0$ 时 $\widetilde{P}_k = P_k$。

证明. 平均池化保持 $[0,1]$ 范围，$\tanh(g_s) \in [-1,1]$，乘积再平移得到区间。 □

该门不会把某位置乘为零，避免因前景支路一次失误而**直接硬删除**候选。但分类分数仍可能下调到阈值以下，实际召回**依然可能下降**。系数允许正负调制，不能把它写成“只增强不抑制”。

12.1 场景监督的精确定义

对可见掩膜 M_i，定义 $U = \max_i M_i$，边界并集 $B = \max_i \mathcal{B}(M_i)$，其中 $\mathcal{B}$ 为 3×3 膨胀减腐蚀。目标先自适应最大池化到 C2 网格，实际 J11 辅助项为

$$\mathcal{L}_{\text{scene}} = \mathrm{BCE}\left([S_f, S_b], \mathrm{MaxPool}([U, B])\right), \quad \lambda_s = 0.1. \tag{31}$$

最大池化希望保留微小正区域，但目标构造用的是训练时已有掩膜栅格；此前已消失的实例不能由最大池化找回。

控制思想的准确借鉴 把深层识别的辅助作用限制为小幅、可关闭的残差，而不是强制覆盖所有浅层细节。这与“受限修正”的工程思维相容，但该网络没有物理被控对象、时域闭环或 PID 控制器。PIDNet 是可引用的启发先例 [8]，不是本网络自动获得控制理论稳定性的依据。

适用边界：共享主干、损失梯度和 TAL 的分类-定位对齐仍把各任务耦合在一起，不能宣称完全解耦。

13 损失推导：已经实现的项与尚未使用的项

13.1 基础掩膜损失不是简单“偏向大目标的全图 BCE”

原基础损失对匹配正样本 a 的 GT 框内像素计算 BCE，再以框面积归一化。其结构可写作

$$\mathcal{L}_{\text{base mask}} \propto \sum_{a\in\mathcal{A}_+} \frac{1}{|\Omega_{g(a)}|} \sum_{p\in\Omega_{g(a)}} \mathrm{BCE}\big(L_a(p), M_{g(a)}(p)\big), \tag{32}$$

最终还按正样本数量和官方增益归一化。因此不能以“原损失完全没有小目标面积归一化”为设计新损失的理由。

13.2 可选 tiny Dice 与可见边界项：J14–J16，不是 J11

下式针对单张图像，代码最后对具有匹配实例的图像取均值。令 $\mathcal{A}_i$ 是 GT i 的匹配系数集合，先平均系数后合成概率 $p_i = \mathrm{Crop}_{b_i}\,\mathrm{sigmoid}(\bar{c}_i^{\mathsf{T}}\mathcal{P})$。实际可选项为

$$\begin{aligned} D_i &= 1 - \frac{2\sum_p p_i(p)M_i(p) + 1}{\sum_p p_i(p) + \sum_p M_i(p) + 1}, \\ w_i &= \mathrm{clip}\Big(\sqrt{256/\max(A_i,1)}, 1, 2\Big), \\ \mathcal{L}_{\text{tiny}} &= \frac{\sum_i w_i D_i}{\sum_i w_i}, \qquad \mathcal{L}_{\text{boundary}} = \frac{1}{n_+}\sum_i \frac{\sum_{p\in\mathcal{B}_i\cap\Omega_i}\mathrm{BCE}(L_i(p), M_i(p))}{\max(|\mathcal{B}_i\cap\Omega_i|, 1)}. \end{aligned} \tag{33}$$

A_i 为掩膜有效面积换算到输入像素后的值，n_+ 是被匹配的实例数；没有匹配的 GT 不进入这些项。**J11 的 tiny/boundary 增益都是 0；J14 为 0.25/0，J15 为 0/0.1，J16 为 0.25/0.1**。所有版本保留标准 box、cls、DFL 和逐候选 mask 项。

13.3 平均系数的必要反例

针对标签 1，若两个候选 logits 分别为 $+8, -8$，则

$$\mathrm{BCE}\left(\frac{8-8}{2}, 1\right) = \log 2 \approx 0.693, \quad \frac{\mathrm{BCE}(8,1) + \mathrm{BCE}(-8,1)}{2} \approx 4.000. \tag{34}$$

BCE 对 logit 为凸函数，平均 logits 的辅助项可能掩盖一个非常差的候选。基础逐候选损失仍保留，但不能证明平均系数 Dice 更强，更不能把 BCE 的 Jensen 不等式套到 Dice 上。

适用边界：GT 边界不能强制圆形或凸包填充，否则会与条带遮挡导致的深凹可见掩膜冲突。3×3 形态学带在 stride 2 原型上约涉及 6 个输入像素，不是精确 3 输入像素边界。

14 控制式梯度预算：有条件的一步下降推导

本节是未来可选方案，不是 J11 已实现的算法。辅助损失大小小，并不保证辅助梯度不伤害主任务。GradNorm、PCGrad 已研究任务梯度尺度和冲突 [9, 10]；这里只建立可审计的局部下降条件，不宣称首次发明梯度控制。

令主损失梯度为 $g_m = \nabla \mathcal{L}_m(\theta)$，辅助梯度为 $g_a = \nabla \mathcal{L}_a(\theta)$，普通梯度下降一步为

$$\theta^+ = \theta - \eta(g_m + \lambda g_a). \tag{35}$$

一阶主损失变化近似为

$$\Delta \mathcal{L}_m \approx -\eta \|g_m\|_2^2 - \eta\lambda \langle g_m, g_a \rangle. \tag{36}$$

若内积为负，辅助梯度可能抵消主任务下降，不能仅凭同号损失增益断言有益。

命题 14.1 (有界辅助梯度下的主损失一步下降). *假设 $\mathcal{L}_m$ 在相关线段上具有 β-Lipschitz 连续梯度，$g_m \neq 0$，$\lambda \geq 0$，且 $\lambda\|g_a\|_2 \leq \gamma\|g_m\|_2$，其中 $0 \leq \gamma < 1$。若步长满足*

$$0 < \eta < \frac{2(1-\gamma)}{\beta(1+\gamma)^2}, \tag{37}$$

则普通梯度下降式(35)满足 $\mathcal{L}_m(\theta^+) < \mathcal{L}_m(\theta)$。

证明. 下降引理给出 $\Delta \mathcal{L}_m \leq -\eta\langle g_m, g_m + \lambda g_a \rangle + (\beta\eta^2/2)\|g_m + \lambda g_a\|_2^2$。由 Cauchy–Schwarz 和三角不等式，上界进一步为

$$\Delta \mathcal{L}_m \leq \left[-\eta(1-\gamma) + \frac{\beta\eta^2}{2}(1+\gamma)^2 \right] \|g_m\|_2^2. \tag{38}$$

式(37)使括号严格为负，结论成立。 □

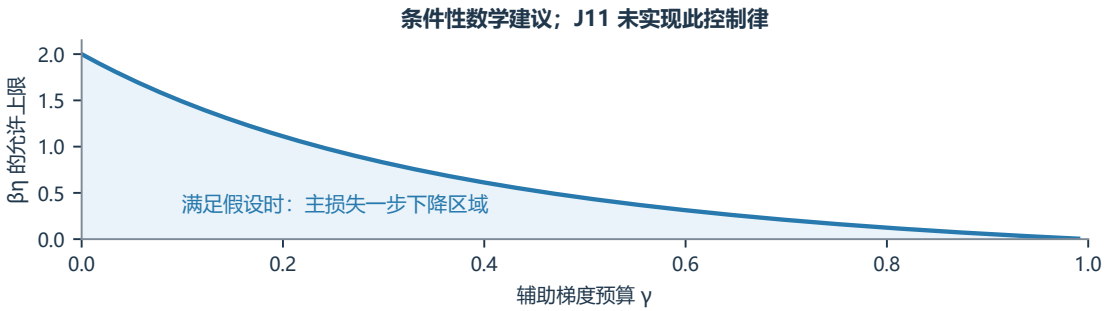


图 7 解析允许步长区域；不是训练结果。辅助梯度预算增大时，最坏情形的安全步长缩小。

适用边界：这个结论不直接适用于带动量 SGD、AdamW、自适应预条件、随机小批量、跳变分配或全局收敛。β 通常未知，不能把图中的上界直接当现成超参数。真正实现前应测量冲突和开销；主梯度为零时也需单独处理。

15 PR 末端推导：横轴不是置信度，零补齐不是新的观测

将候选按置信度降序排列，前 k 个候选的真阳性和假阳性为 T_k, F_k，有 N_{GT} 个真实实例，则

$$P_k = \frac{T_k}{T_k + F_k}, \qquad R_k = \frac{T_k}{N_{\mathrm{GT}}}. \tag{39}$$

PR 图横轴是 **Recall**，不是 confidence。横轴在 0.85 左右跌落不能解释为“置信度 0.85 导致精度突然为零”。应另看 Precision–Confidence、Recall–Confidence 曲线和原始 TP/FP。

15.1 当前实现的端点约定

已核对本地 `metrics.py` 与当日 Ultralytics 官方 main 源码 [11]，AP 辅助数组结构为

$$\texttt{mrec} = [0, R_1, \ldots, R_{\max}, R_{\max}, 1], \qquad \texttt{mpre} = [1, P_1, \ldots, P_K, 0, 0]. \tag{40}$$

重复 $R_{\max}$ 对应人为加入的零端点；其后取单调包络并插值积分。所以最高观测召回之后贴零的部分可能主要由**端点补齐**呈现，不能把它逐点解释为“这些召回水平真的评估到了零精度”。

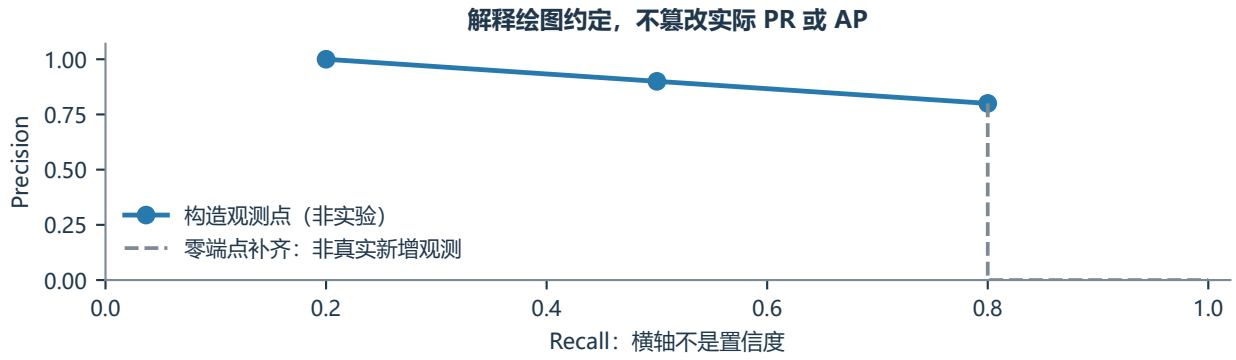


图 8 人工观测点仅到 Recall=0.8。灰色虚线解释零端点补齐，不表示真实新增观测，也不是 J11 或其他模型的实际 PR。

15.2 真正需要优化的是哪些量

$R_{\max} < 1$ 仍意味着在当前候选生成、IoU 匹配与推理协议下有 GT 未找回。原因可能是输入细节、目标混淆、候选过滤、掩膜不达 IoU 或合并错误。小目标是**重要候选原因**，但需要尺度分层 TP/FN 证明，而不能仅从末端形状定性。

严禁把曲线画好看当解决问题 不删除零段、不改变端点来刷 AP、不把内部栅格 AP 冒充 COCOeval。正式比较用相同的官方评估器和设置；重点报告低阈值召回上限、极小目标 recall、固定 precision 下的 recall、mask AP50/50–95 及 split/merge 错误。美化端点不能修复漏检。

16 哪些优势已有证据，哪些必须通过消融证实

16.1 当前可保留的三条研究主线

一，细节与实例语义的任务分流。小目标误差敏感性有精确推导；细节进入掩膜原型的结构事实可核对；历史配对诊断支持输入/推理尺度的重要性。但候选仍在 P3/P4/P5，不能把 mask 更细当成召回问题已经解决。

二，低预算的一次式竞争融合。有明确的凸组合性质和可解释的权重梯度；相比模块反复堆叠，更容易隔离来源和测量路径代价。然而 ASFF 已有同类权重思想，真正贡献应来自任务约束下的拓扑、预算分配和可靠消融。

三，有限记忆的差分上下文与受限识别修正。零行和带来公共分量消除，固定槽数降低读取矩阵复杂度；软门不直接硬删除候选。但公共分量不等于叶片，先验不等于正确识别；应保留反例和无差分对照。

表 3 直接对应现有 J 系列的最小可归因验证关系

比较	隔离的主要因素	应读取的指标，而非只看总 AP
J00 与 J11	同协议系统收益	mask AP50/50–95、R、参数、GPU 端到端耗时
J05 与 J06	亮度/局部对比入口	果叶误报、颜色扰动、尺度 R
J05 与 J08	竞争权重与均匀融合	小目标 R、权重熵、融合失败样例
J11 与 J12	场景支路及监督	分类误报、固定 precision 的 R
J11 与 J13	差分与普通读取	背景误报、tiny R、上下文图
J11/J14/J15/J16	tiny/边界损失项	mask AP、Boundary F1、GT 无正样本率

正式结论需在 grouped_dedup 的相同 train/val 划分、初始化、优化器、学习率、图像尺寸、AMP、增强、掩膜栅格与评估协议下比较；主基线和最终方法各三 seed，保留独立 test 作最终确认。J 系列的 scratch、AMP=false、mask_ratio=2、copy_paste=0.3 及混合输入是**协议的一部分**，不能与旧 78/83 分基线直接做结构因果比较。

最终回答 J11 有值得验证的机制，也已有低参数、低估算 FLOPs 的实现证据。本文数学能够证明的是算子性质、误差敏感性、表达限制和条件性优化边界；**不能证明 AP、召回必提高，更不能证明它已经是最强模型。**能发论文的“强”必须由同协议多 seed、难例机制和硬件实测共同兑现，而不是由图复杂或公式多来决定。

参考文献：思想来源与实现差异

以下主要链接指向论文或官方来源。数学证明由本文独立展开；引用不代表复制原论文的完整网络，也不代表原论文在其他数据集上的增益可直接迁移到柑橘。

参考文献

[1] Chen J, Kao S-h, He H, et al. *Run, Don't Walk: Chasing Higher FLOPS for Faster Neural Networks*. CVPR, 2023. 论文与元数据；作者代码。部分通道空间处理的先例，不是当前 JStage 的完整实现。

[2] Liu S, Huang D, Wang Y. *Learning Spatial Fusion for Single-Shot Object Detection*. arXiv:1911.09516, 2019. 原论文。空间自适应尺度融合的先例。

[3] Pu Y, Ying J, Li Q, et al. *Linear Differential Vision Transformer: Learning Visual Contrasts via Pairwise Differentials*. NeurIPS, 2025. 原论文；作者代码。原方法具有完整视觉对比结构，JContext 为简化任务改写。

[4] Ye T, Dong L, Xia Y, et al. *Differential Transformer*. ICLR, 2025. 原论文。差分注意力思想先例；当前固定差分系数为 1。

[5] Bolya D, Zhou C, Xiao F, Lee Y J. *YOLACT: Real-Time Instance Segmentation*. ICCV, 2019. 原论文。原型和实例系数的分解先例。

[6] Chen L, et al. *Frequency-aware Feature Fusion for Dense Image Prediction*. arXiv:2408.12879, 2024. 原论文；作者代码。当前 JFusion 未实现其完整频率感知与校正机制。

[7] Akyon F C, Altinuc S O, Temizel A. *Slicing Aided Hyper Inference and Fine-tuning for Small Object Detection*. ICIP, 2022. 原论文；作者代码。

[8] Xu J, Xiong Z, Bhattacharyya S P. *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers*. CVPR, 2023. 原论文。当前网络未实现 PID 控制器；受限残差只作为设计类比。

[9] Chen Z, Badrinarayanan V, Lee C-Y, Rabinovich A. *GradNorm: Gradient Normalization for Adaptive Loss Balancing in Deep Multitask Networks*. ICML, PMLR 80:794–803, 2018. 正式论文。

[10] Yu T, Kumar S, Gupta A, et al. *Gradient Surgery for Multi-Task Learning*. NeurIPS, 2020. 正式论文。梯度冲突处理先例；本文的预算推导不是已经实施的 PCGrad。

[11] Ultralytics. *ultralytics/utils/metrics.py*, official main source. 官方源文件。核对日期 2026-10-01；正式实验应冻结具体版本。

附录：复核入口、数学检查与来源账本

实现与证据文件

下列路径相对主工作副本 `1_SEVER/code/ultralytics-main-new/`：

- `0_orange_yaml/J_series/J11_synthesis.yaml`：完整结构与头部损失参数。
- `ultralytics/nn/modules/citrus_j.py`：入口、主干、融合、上下文、实例头。
- `ultralytics/utils/citrus_j_loss.py`：场景与可选 tiny/边界损失。
- `docs/J_STRICT_REVIEW_20261001/REPORT.md`：历史结果、数据与研究假设重审。

数据来源为工作区 `_work/` 下的三个诊断产物：

- `20261001_j_strict_review_v3/audit.json`：正式划分几何、符号检查与反例。
- `20261001_j/evidence/bounded_evidence.json`：历史冻结权重配对诊断。
- `20261001_j/profile/model_costs.csv`：本地 CPU 参数/FLOPs/前向诊断。

配图脚本不修改这些源文件；新文档目录的 `verification.json` 保存源文件 SHA-256，`figures/` 下 CSV 保存数值图的精确来源字段，便于核对。测试集未用于挑选结构或调参。

已核验与未核验事项

检查	结论与范围
SymPy 精确化简	softmax 混合梯度残差为 0；方形 IoU 分数正确；压缩核反例正确；预算步长边界残差为 0
源码公式对应	核对投影顺序、差分固定系数、320 原型、场景门范围及 J11 的实际损失开关
图形证据性质	解析曲线/人工槽位例子与历史实验分开；未虚构 J11 PR、训练指标或多 seed 方差
LaTeX 与渲染	以 XeLaTeX 编译，公式编号和引用可追踪；最终 PDF 逐页渲染检查
尚无的实验	J11 同协议三 seed 正式精度、独立测试、实际 GPU 延迟、果叶混淆归因、增强后正样本诊断

可复现编译

在包含此源码和 `figures/` 的目录，以 XeLaTeX 连续编译两次：

```
xelatex -interaction=nonstopmode -halt-on-error J11_math_derivation.tex
xelatex -interaction=nonstopmode -halt-on-error J11_math_derivation.tex
```

Windows 使用系统中文字体，正文宋体、英文 Times New Roman。若迁移到无 Windows 字体系统，修改 `fontset=windows` 为可用字体集，不改变公式或科学结论。

论文使用建议 可以把精确算子性质、复杂度分析和反例整理成方法/补充材料；“为什么更强”必须在正式实验之后用真实结果回答。不要把本文作为保证涨点、保证最强或保证投稿等级的证明。